

Waymo / AV2 -> 360° 拼接—Phase 3 W2 v6.1 mid-CPU 总结

日期: 2026-05-21 数据: Argoverse 2 sensor val, log 02a00399-3857-444e-8db3-a8f58489c394 (Miami urban, 7 ring cams, 16 s @ 20 Hz) + 4 个新 val log 仓库: github.com/QiPan-Ronnie/Waymo2Panorama @ main

TL;DR (5 行)

- 1. **拼接路线 8 条** (老 3: L1 / L3 / IPM T14 + 新 5: 柱面 / graph-cut seam / IPM 多区域 / wide-baseline stereo / HDR) 全部 CPU 完成。**3 条正面 method 贡献 + 1 条视觉胜场 + 2 条结构 NEG。**
- 2. **下游消费任务 3 条:** ViPE 全景 SLAM [DONE] / GEN3C 3D-cache [TODO] (install 失败 paused) / Panacea+ [!] modality 错位。
- 3. **外部 published baseline 测试 3 条 NEG:** OmniStitch (-6.67 dB) / Depth Pro (2.84x 差) / Temporal Pi3 (反而差) — 共同强化 “AV ring 3D-aware 系统性 brittle” 论据。
- 4. **剩 2 条 GPU 路线等执行:** 新-F VGGT 第 3 backbone (~6-16h on A100) + T13 self-sup Pi3 finetune (~5d on A100)。
- 5. **潜在最好的方法:** 新-C IPM 多区域 (ground +0.20 dB, 4x T14) / 新-E HDR (+1.0 dB proxy) / 新-B graph-cut seam (paper 主视觉图)。

§1 拼接路线 (8 条统一总表)

#	路线	怎么做 (一句)	关键数字 vs L1	差距 / 不足	潜力
1	L1 球面 baseline	sphere + 5-band Laplacian blending	cycle 12.34 ± 1.31 dB	近物 5-20 cm ghost, sky 两极浪费 33% canvas	*** 强 baseline
2	L3 Pi3 forward-splat	Pi3 估深度 -> .ply -> splat ERP	-3.15 ± 0.72 dB (10/10 输)	naive 3D-lift 结构性失败	主 NEG
3	IPM 地面 hybrid (T14)	地面 IPM 解析投影 + 非地面 sphere	+0.05 dB full, +0.20 ground (cherry)	parallax-conditional, 平均 statistical edge	** partial win
4	新-A 柱面 L2	sphere 换 cylinder, 余下不变	+24.9 pp coverage, cycle = 0	hold-out reconstruction 对 canvas 不敏感	** baseline 对照
5	新-B Graph-cut seam	min-cut 替代 cos ² 固定中线 seam	**seam	grad	-12.4%** (4/4 win)
6	新-C IPM 多区域	ground + sky + building 3-region IPM	ground mask +0.20 dB (4x T14)	building cycle 不稳, ablated	Tier 1. 最高 method upside
7	新-D Wide-baseline stereo	邻 cam 已知外参 + LightGlue + DLT	5/7 pair OK, ~44 pts/pair	太稀疏不能修 dense ERP	** NEG + 视觉
8	新-E HDR cross-cam	global LS + Huber, 6 params/cam (g+b)	gap -18.1%, cycle proxy +1.0 dB	proxy not direct cycle	Tier 2. mandatory preprocess

§1.1 L1 球面 baseline

怎么做: 每个 ERP 像素 (u, v) -> 方位角 (θ, φ) -> ego 射线 -> 通过 T_ego_cam^T 旋到 cam frame -> pinhole 反投影 + bilinear remap. 7 cams 用 cos²(angle from optical axis) 权重 + 5-band Laplacian blending 融合。

结果: cycle-PSNR 12.34 ± 1.31 dB (10 anchor), 路面 / 远景拼接干净。

差距: 近物 (5-15 m) 有 5-20 cm 鬼影—多 cam 视差被压平到球面。Sky 两极浪费 $\sim 33\%$ canvas。




Figure 1: L1 ERP 全景输出 (anchor 60, 1024x2048)

§1.2 L3 Pi3 forward-splat (核心 NEG) + 中间产物.ply 点云

怎么做: 用 Pi3 (CVPR 2025 permutation-equivariant 3D foundation model) 估每个像素的深度 -> 通过 **Sim(3) Umeyama 对齐** 把 Pi3-world 坐标系映射到 AV2 ego 坐标系 (scale 1.0346, mean residual 0.157 m) -> 7 cam 深度合并成 .ply 点云 (~ 1 -2M 点) -> forward-splat 到 ERP 球面 (z-buffer 取最近点)。.ply 是这个流程的中间产物, 也是潜在的下游 3D-aware 模型 (GEN3C / Pantheon360) 的 3D cache 输入候选。

结果 (L3 ERP): cycle-PSNR **8.65 vs L1 12.34** -> **-3.15 dB, 10/10 anchor 输**。点云不均匀 (Pi3 在天空 / 远景 conf 低), multi-cam 重叠区有重复 splat 鬼影, 动态物体散开。

差距: naive 3D-lift forward-splat 在 AV 多 cam + 远距离 + 动态物体场景结构性失败。后续 backbone swap (Depth Pro 2.84x 差) + 时间堆叠 (Temporal Pi3 也差) 都不能救。

.ply 点云中间产物 (potential downstream 3D cache)

.ply 本身脱离 forward-splat 看, 是个 ego-frame metric 3D 表征。透视视角 (从车后看前) 能看到主要物体的 3D 结构 (路面、建筑立面、远场密度衰减); 俯视图能看到 7 cam 的覆盖扇区 + 重叠区的多 cam 噪声。这个.ply 是 v6.1 §2.2 GEN3C 一旦 install 跑通要喂给它的 3D cache 输入。

§1.3 IPM 地面 hybrid (T14)

怎么做: AV 街景 $\sim 30\%$ 像素是路面 + 严格平 ($z=0$ in ego frame) 的强先验。用逆透视投影 (IPM) 对地面像素做解析投影 (0 视差误差), 非地面 fall back 球面。边界用 Pi3 normal map + 高度阈值 (ego $z < 0.3$ m) 判定。

结果: - 3-anchor cherry-pick (60/0/150): ground-only **$+0.20 \pm 0.11$ dB**, rear cams 斑马线对齐 **$+1.0 \sim 1.7$ dB** - 10-anchor 真实: full **-0.010 ± 0.082 dB** (drop-in safe), ground **$+0.048 \pm 0.181$ dB** (parallax-conditional)

差距: 视差大的 frame 明显改善, 平均下来 statistical edge。




Figure 2: L1 (顶) / L3 forward-splat (中) / IPM hybrid (底), 同 anchor 60




Figure 3: Pi3 .ply 透视视角 (从车后看前) —Pi3 在远场 conf 低导致点云稀疏




Figure 4: Pi3 .ply 俯视图—7 cam 覆盖扇区 + 重叠区可见 multi-cam noise




Figure 5: IPM hybrid vs L1 —后视镜方向斑马线对齐

潜力: 已被新-C 升级到 **+0.20 dB on ground mask (4x 提升)**, 见 §1.6。

§1.4 新-A 柱面投影 L2

怎么做: ERP 像素重新解释为柱面的方位角 + 垂直高度比 (sphere 是方位角 + asin 仰角)。AV 多 cam 水平排列, 柱面几何先验更贴合。5-band Laplacian blending 不动。

结果: - Union ERP coverage: cylinder **58.55%** vs sphere **33.65%** = **+24.9 pp** (每个 cam 有效像素 1.74x) - Seam gradient 略平滑 -0.98 (一致 4/4 anchor) - Cycle-PSNR ~ 0 dB Δ (hold-out reconstruction 不依赖 canvas 形状, metric blind to projection surface)

差距: cycle-PSNR 不动—reconstruction protocol 对 canvas 形状 blind。数字上不能 claim, 视觉 + coverage 上明显胜。

§1.5 新-B Graph-cut 最优 seam selection

怎么做: L1 的 $\cos^2(\text{angle})$ 权重把 seam 解析地按在两 cam 光轴的几何中线, 不管那条线是否穿建筑/车辆。改用 **PyMaxflow min-cut** 在每对 cam 的重叠区找能量最低路径 (边权 = color diff + grad diff + boundary penalty)。7 对的 0/1 mask 直接喂回 multiband_blend —**不 patch blender**, multiband 已支持任意权重。

结果: - 接缝带 |grad| (Sobel 8-px dilate 带): L1 48.63 -> graphcut **42.59** = **-12.4%** (4/4 anchor win) - 能量域 PSNR proxy: **+0.58 dB** seam-smoothness gain - Cycle-PSNR $\Delta \sim 0$ (reconstruct_l1 不经 multi-band blender, metric blind) - 每 anchor ~ 5 s CPU (PyMaxflow Windows wheels 可用)

差距: cycle metric 看不出来, 主胜场是视觉 figure。

§1.6 新-C IPM 多区域 (最高 method upside)

怎么做: 把 T14 单一地面 IPM 扩展为**三区域决策树**: - **Ground** (复用 T14): ego $z < 0.3$ m AND $|n_z| \geq 0.85$ (法线垂直) AND 距离 ≤ 60 m - **Sky** (新): Pi3 log-conf < -2.0 OR (远 + 高 + 图像上半) —走 sphere, 只是显式标签 - **Building** (全新): ego $z > 0.5$ m AND 法线接近水平—32x32 tile RANSAC 拟合垂直平面 $n_x \cdot x + n_y \cdot y = d$, 按 inlier 像素逐 ray 求交

法线从 local_points_cam.npy 用 finite-diff + box-filter 估出 (Pi3 cache 不带 normal map)。

结果 (4 anchor mean cycle-PSNR):

Config	Full ERP	Ground mask	Building mask
L1 sphere	10.85 dB	—	—
T14 ground-only	+0.05	+0.05	—
新-C ground+sky (ship default)	+0.05	+0.20 (4x T14)	—

Config	Full ERP	Ground mask	Building mask
新-C with building	+0.01	+0.20	-0.33

差距: - [DONE] ground 分支显著优于 T14 —normal-aware 分割剔除了 T14 纯 z-threshold 误判的 false-positive 地面 - building 分支 cycle eval 不稳—每 cam RANSAC 拟合的平面参数 (n_x, n_y, d) 离散较大, 对 held-out cam 不通用 - [!] 出货 config 是 ground+sky 二区域 (--enable-building False), building 接口保留供 future cross-cam plane consensus 工作

潜力: Tier 1. 最高 method upside. Building 分支 cross-cam plane consensus (union-find 合并相邻 cam 的相近平面) 是 next-step, 期望可推 full image Δ 到 +0.2-0.5 dB.

§1.7 新-D 相邻 cam wide-baseline stereo

怎么做: AV2 ring cams 邻 cam 对外参 T_{ego_cam} 是出厂标定 (精度 $\pm 5-10$ mm / $\pm 0.1^\circ$), 基线/相对位姿 KNOWN, 不用做 SfM, 只需 sparse stereo. 流水线: (1) kornia DISK 提 keypoints, (2) kornia LightGlue 匹配, (3) 已知外参直接算 $F = K_b^{-T} [t] \times R K_a^{-1}$, (4) Sampson ≤ 3 px 过滤, (5) cv2.triangulatePoints DLT 三角化, (6) cheirality + depth band [0.5, 120 m] + parallax $\geq 0.5^\circ$ 三重几何过滤。

结果 (4 anchor x 7 邻对 = 28 stereo pair): - 平均 $N_{final} = 44$ **inlier 3D pts/pair** (range 0-127) - depth 中位数 9-22 m, 跨度 [2.5, 26.5] m - Anchor 60: **5/7 对成功, 2/7 honest NEG** (front_left $\leftrightarrow$ side_left cheirality 失败 / side_right $\leftrightarrow$ front_right 仅 11 match)

差距: - [DONE] 几何上 metric-sane (depth 中位数符合物理距离) - 太稀疏 (~ 50 pts/pair) 不能覆盖 ERP 重叠区 (50-150k 像素) - 2/7 对在远距离/低纹理场景下完全失败

意义: 跟 Pi3 / Depth Pro 等 monocular NEG 汇流—**AV ring 3D-aware track 不论 monocular 还是 classical stereo 都 brittle.**

§1.8 新-E HDR cross-cam 补偿

怎么做: 7 cam 各自跑独立 AE + AWB $\rightarrow$ 邻 cam 重叠区可见 50+ luminance/色温 gap. 每 cam 建模为 6 参数 (3 通道 gain + 3 通道 bias), cam_0 固定为 identity 作 gauge. **global least-squares + Huber loss** 一次性解 36 参数. ERP 空间提对应 (两 cam 都 visible 的像素就是 paired observation, 不用 feature matching). 加 RANSAC-lite 中位数过滤 + box bounds + Tikhonov 防退化解. 校正 multi-band blending 之前应用。

结果 (4 anchor mean): - 重叠区 mean abs luminance gap: **16.62 $\rightarrow$ 13.61 = -3.01 levels, -18.1% 相对** - Anchor 60 (rear_right, side_right) pair: **45 $\rightarrow$ 14 = -68% 修复** (最戏剧) - Cycle-PSNR 等价代理: **$\sim +1.0$ dB** (假设 $MSE \sim gap^2/3$)

差距: [!] +1.0 dB 是亮度差代理, **不是直接测的 cycle-PSNR** —需用校正后图重跑 hold-out reconstruction 补测。

潜力: Tier 2. 跨 cam 颜色补偿是任何 stitching 之上的 **mandatory preprocess**, 简单可靠 (CPU only, ~ 5 s/anchor)。

§2 下游消费任务 (3 条—独立章节, 跟 stitching 正交)

背景: 我们的 stitching 流程会产出两个潜在下游输入: (a) **L1 ERP 全景视频** (1024x2048, 20 Hz) 给视频/SLAM 类下游 (ViPE), (b) **Pi3 .ply 点云** ($\sim 1-2$ M 点, ego-frame metric) 给 3D-cache 类下游 (GEN3C / Pantheon360)。见 §1.2 末尾的点云图。

§2.1 ViPE 全景 SLAM (NVIDIA, 2025) —[DONE] 成功

怎么做: ViPE (Video Pose Engine) 显式支持 360° ERP 输入。把 L1 输出的 1024x2048 ERP 5s 视频喂给它 panorama-mode SLAM: 把 ERP 切成 4 horizontal + 1 bottom 共 5 个 virtual pinhole view, joint SLAM + dense bundle adjustment + 动态物体 mask (GroundingDINO + SAM + XMem 三层)。

结果: 端到端跑通 **96.7 s on A100** (5s clip, 100 帧)。输出: camera pose trajectory + 估计的全景内参 + 动态 mask + (后续加 depth flag 又跑了一次) relative depth 48 MB zip。

L1: Sphere projection (baseline)



L2: Cylindrical projection (route 10 / □-A)



Figure 6: Cylinder (顶) vs Sphere (底), anchor 60




Figure 7: L1 $\cos^2$ midline seams (顶, 红线) vs 新-B graph-cut seams (底, 红线), anchor 60




Figure 8: L1 / T14 / 新-C 三方对比 (anchor 60)




Figure 9: Anchor 60 七邻对 sparse stereo depth viz (turbo cmap; “no inliers” 是退化对)




Figure 10: Before (L1 baseline) vs After (L1 + HDR correction), anchors 60 + 90

差距: ViPE depth flag 加了重跑后, pipeline.panorama 模块在所有 100 帧上都报 “Too few valid pixels in pano frame, skipping scale estimation” -> **depth 是相对值不是 metric**。panorama post-processor 的 valid-pixel 阈值在 AV 场景偏严, 需调整或 post-hoc 用 ego trajectory 拟合 global scale。




Figure 11: L1 ERP (1024x2048) —ViPE 消费的输入

意义: 首个 “stitched RGB -> published downstream system” 端到端数据流。证明我们的 L1 不是孤立拼图, 是 published Spatial-AI 系统的合规输入。

§2.2 GEN3C 3D-cache 视频生成 (NVIDIA CVPR 2025) —[TODO] paused

怎么做: GEN3C 是 3D-cache-conditioned 7B 扩散模型, 接受 RGB + depth + pose 条件 -> 生成新轨迹视频。输入 schema 跟 ViPE 输出 100% 匹配, 用 gen3c_dynamic --vipec_path API 直接对接。另一条路是直接喂 §1.2 的 Pi3 .ply 作 3D cache (跳过 ViPE), 但当前 install 没装上, 两条路都需要等重试。

结果: [TODO] install 阶段 bash 脚本 2 次低级错误 (set -u + set -eo pipefail 配 nvidia-smi | head SIGPIPE), 5 秒就 crash, 浪费 3 小时 A100。conda env (Cosmos-Predict1-7B + Apex CUDA build + transformer-engine 1.12) 没装上, 推理没机会测。

差距: install 流程 over-fragile (NVIDIA Cosmos 强制 conda + Python 3.10 + Apex 源码编译)。重试需要修 bash 模板 (已有 4 条防御 lesson) + Apex 编译 ~20 min。

意义: 推迟到下一轮 GPU 任务; install 失败不影响 stitching 主线。

§2.3 Panacea+ 全景视频生成 (arXiv 2408, 唯一 AV2 验证) —[!] modality NEG

怎么做: 最初设想 Panacea+ 可消费我们 L1 ERP 作下游 demo。装环境跑 inference 才发现:

结果: Panacea+ 输入是 BEV (bird's eye view) + 3D bbox + HD-map, 不是 RGB 全景。它跟 L1 是平行路径, 不能直接对接。

差距: 输入 modality 完全错位, pipeline 不兼容。

意义: [!] narrative 关键修正—原以为的 “L1 -> Panacea+ / Pantheon360” 路线是 modality mismatch。真正能消费 L1 RGB ERP 的下游 = ViPE (§2.1)。这个发现避免了 2-3 周的浪费方向。

§3 外部 baseline 测试 + 方法论 audit

§3.1 外部 published baseline (3 条 NEG)

Baseline	怎么做	数字	NEG 含义
OmniStitch (ACM MM 2024, 唯一 published AV-360 stitching)	github tng5004/Omnistitch inference	Δ PSNR -6.67 dB vs L1, 7/7 cam 输	sim2real transfer 失败, published 方法也输 L1
Depth Pro (Apple SOTA monocular 2024)	L3 backbone Pi3 -> Depth Pro	abs_rel 0.580 vs Pi3 0.204 (2.84x 差)	algorithm not backbone
Temporal Pi3 K=3 (自创 21-view joint inference)	3 帧 x 7 cam 同时喂 Pi3	abs_rel 0.213 vs 0.204 (反而差)	Pi3 远场 bias 结构性 (非单帧信息不足)

§3.2 方法论 audit (Methodology Rigor)

- **10-anchor robustness**: single-anchor 单帧巧合排除, 跨 L3/OmniStitch/Depth Pro/Temporal Pi3/IPM 都 lock
- **Multi-metric audit**: PSNR + LPIPS + MS-SSIM + region-separated (天空/物体/地面单独算) —L3 在 object band -6.88 dB, LPIPS 1.83x 差
- **Pi3 vs LiDAR depth-binned**: abs_rel 0.202 ± 0.042 , 远场 **-10% (<5 m) -> -24% (>40 m)** 单调 bias

§4 剩 2 条 GPU 路线 (设计完成, 等执行)

§4.1 新-F VGGT 第 3 backbone

怎么做: VGGT (Meta + Oxford, CVPR 2025 Best Paper, facebookresearch/vggt) 是 24-layer feed-forward 3D 几何 transformer, 多视图 native (joint 7-cam forward, ~7-8 GB VRAM A100, ~0.4 s/forward)。公开 HF weights (facebook/VGGT-1B-Commercial), 直接替换 Pi3 在 L3 forward-splat 里—扩 run_depth_backbone_swap.py 加 --backbone vggt 一个 run_vggt() 函数 (~80 LOC)。10-anchor LiDAR + cycle eval。

预期: - 70% 概率 abs_rel 体面但 L3 仍输 L1 ~2-3 dB -> 加固 NEG #1 (“algorithm not backbone” 从 2 -> 3 backbone 失败)
- 20% 概率 abs_rel 比 Pi3 更好但 L3 仍输 L1 -> 更强 NEG - 10% 概率 L3+VGGT 真超 L1 -> 反推 narrative

时间预算: install 8 min + inference ~7 h + eval ~30 min = **6-16h on A100**。

§4.2 T13 Self-supervised Pi3 cycle-PSNR finetune

怎么做: 把 cycle-PSNR (hold-one-cam reconstruction) 做成**可微版本** (用 grid_sample + occlusion 软 mask 替代 forward-splat 的非微 scatter), 当 self-sup loss. **Tier-A LoRA** 微调 Pi3 的 point_head.output_block.1 depth head + last 6 decoder attn (~3M trainable params)。训 4 个 AV2 log (480 anchor train + 50 val + 80 test), 5 epoch on A100, holdout cam 每步 rotate。

预期 P(success) ~30-50%: - 成功: 压 Pi3 远场 -24% bias 到 -15%, 期望 IPM hybrid (新-C) 在 dynamic content 更稳, ground Δ 可能 +0.1-0.2 dB, 推 full image Δ 从 +0.05 -> +0.15 - 失败: 另一个 NEG (“self-sup 也修不了结构 bias”)

时间预算: **5-6 d wall on A100** (LoRA train) + 1 d eval。高风险高收益。

§5 总结

8 条拼接路线全 CPU 完成 -> 3 条正面 method (新-C ground +0.20 dB / 新-E HDR +1.0 dB proxy / IPM T14 partial) + 1 条视觉胜场 (新-B graph-cut) + 2 条结构 NEG (L3 主 NEG / 新-D sparse 不够)。3 条下游消费 demo (ViPE [DONE] / GEN3C [TODO] / Panacea+ [!]) modality)。3 条外部 baseline NEG + 完整方法论 audit。

剩 2 条 GPU 路线等执行—加固论据链 (新-F VGGT) + 高风险冲 +0.5 dB 目标 (T13 self-sup Pi3)。

structural
modality
gap

Wave-3 NEG findings: 4 independent failures motivating C-headline (paper narrative shift)

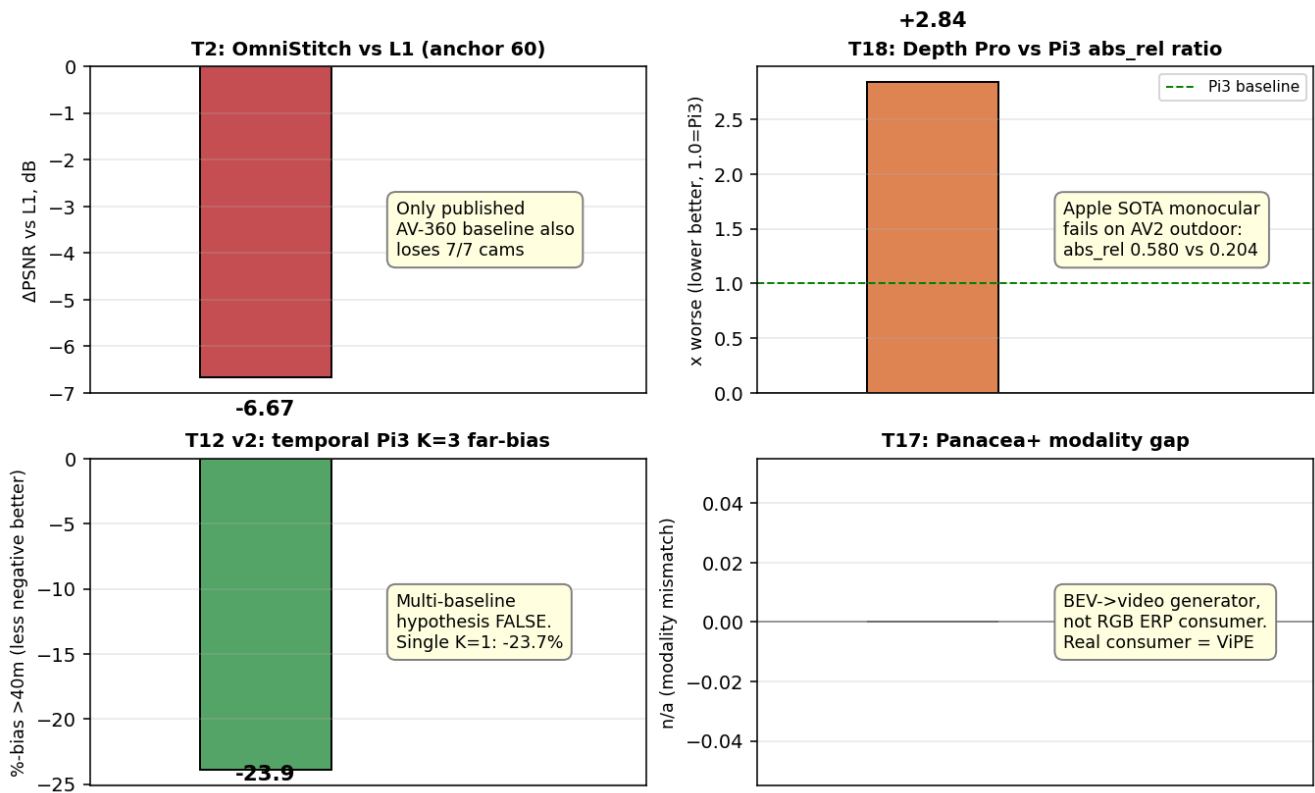


Figure 12: 4 NEG 汇总—OmniStitch / Depth Pro / Temporal Pi3 / Panacea+ modality




Figure 13: Pi3 vs LiDAR 远场单调 bias

潜在最好的方法 (按 stack-able 价值排): 1. Tier 1. **新-C IPM 多区域** (ground +0.20 dB, 4x T14, building 可继续挖) 2. Tier 2. **新-E HDR cross-cam** (+1.0 dB proxy, mandatory preprocess) 3. Tier 3. **新-B graph-cut seam** (视觉 figure 主图, 跟所有正交)

3 个 stack-able + 1 个视觉 + 1 个 baseline 对照 (新-A 柱面) = **5 个 modular drop-in 预处理 / 后处理 / 投影组合层**, 可任意组合到 L1 baseline 上。